

LAPORAN ANALISIS KODE MACHINE LEARNING

SUPERVISED LEARNING



Disusun Oleh

Nama	: Muhammad Yusuf Arrayyan
NPM	: G1A024009
Kelas	: A

Dosen Pengampu

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

PENDAHULUAN

1.1 Latar Belakang

Buku Introduction to Machine Learning with Python membahas supervised learning, yaitu pembelajaran mesin ketika setiap data memiliki target yang ingin diprediksi. Notebook memperkenalkan klasifikasi dan regresi melalui dataset sintetis serta dataset nyata. Berbagai algoritma dibandingkan untuk menunjukkan hubungan antara data, fitur, parameter, kompleksitas model, dan kemampuan generalisasi.

Laporan ini menganalisis seluruh kelompok kode pada tema supervised learning secara berurutan. Pembahasan tidak hanya mencatat skor akurasi atau R kuadrat, tetapi juga menjelaskan tujuan kode, proses komputasi, makna hasil, pengaruh parameter, dan keterbatasan setiap metode.

1.2 Tujuan Analisis

Analisis ini bertujuan untuk membahas dan mendokumentasikan seluruh kode serta materi supervised learning secara lengkap. Pembahasan mencakup konsep klasifikasi dan regresi, dataset yang digunakan, alur fit, predict, dan score, generalisasi, underfitting, overfitting, KNN, model linear, naive Bayes, decision tree, ensemble, support vector machine, neural network, serta estimasi ketidakpastian. Setiap bagian kode dijelaskan berdasarkan fungsi, data, parameter, proses komputasi, keluaran, interpretasi, dan keterbatasannya. Analisis juga membandingkan hasil model, membahas pengaruh regularisasi dan scaling, serta menyusun kesimpulan dan saran berdasarkan keseluruhan materi.

1.3 Sumber dan Metode Analisis

Sumber utama analisis adalah notebook kode G1A024009_Laporan_Kode_Supervised_Learning.ipynb yang membahas supervised learning. Laporan disusun dengan mengikuti urutan kode, membaca tujuan setiap blok program, mencatat dataset dan parameter yang digunakan, kemudian menjelaskan proses komputasi, keluaran, interpretasi, dan keterbatasannya. Angka dapat berubah apabila kode dijalankan dengan versi pustaka, perangkat, atau random state yang berbeda.

Metrik yang digunakan meliputi akurasi, R kuadrat, skor data latih, skor data uji, koefisien, intercept, feature importance, decision function, dan probabilitas kelas. Perbandingan skor data latih dengan skor data uji digunakan untuk mengenali indikasi overfitting.

RANGKUMAN DATA DAN ALUR KODE

2.1 Dataset Utama

Data	Ukuran atau karakteristik	Bagian kode
Forge	26 titik dan 2 fitur	Klasifikasi KNN dan visualisasi batas keputusan
Wave	40 titik dengan 1 fitur utama	Regresi KNN dan model linear
Breast cancer Wisconsin	569 observasi dan 30 fitur; 212 malignant serta 357 benign	Klasifikasi, scaling, PCA, SVM, ensemble, MLP
Boston dan extended Boston	506 observasi; 13 fitur asli dan 104 fitur hasil ekspansi	Regresi linear, Ridge, dan Lasso
Blobs	Data buatan dengan pusat kelompok terkontrol	Klasifikasi multiclass
Moons dan circles	Data dengan bentuk melengkung	SVM nonlinear
Iris	150 observasi dan 3 kelas	Decision function dan probabilitas multiclass

2.2 Alur Umum Kode

Sebagian besar kode mengikuti pola yang sama. Data dimuat atau dibuat, fitur dan target dipisahkan, data dibagi menjadi data latih dan data uji, model dibuat, lalu model dilatih menggunakan fit. Setelah itu model digunakan untuk prediksi dan skor dihitung dengan score atau metrik khusus. Keluaran divisualisasikan agar hubungan antara model dan data dapat diamati.

2.3 Konsep Evaluasi yang Muncul Berulang

Dalam evaluasi model, skor data latih yang tinggi tetapi skor data uji yang jauh lebih rendah mengindikasikan model terlalu kompleks dan berpotensi mengalami overfitting. Sebaliknya, skor data latih dan data uji yang sama-sama rendah dapat menunjukkan bahwa model terlalu sederhana atau fitur yang digunakan belum memadai. Karena itu, perbedaan performa pada kedua data perlu dibaca bersama dengan kompleksitas model, bentuk fitur, dan tujuan prediksi.

Scaling harus dipelajari dari data latih, kemudian diterapkan pada data uji menggunakan scaler yang sama agar informasi dari data uji tidak masuk ke proses pembelajaran. Random state membantu membuat eksperimen dapat diulang, tetapi tidak menggantikan validasi dengan pembagian data lain. Model yang lebih rumit juga tidak otomatis memberikan generalisasi yang lebih baik karena hasil akhirnya tetap dipengaruhi kualitas data, pemilihan parameter, dan kesesuaian metode.

ANALISIS LENGKAP: SUPERVISED LEARNING

3.1 Pengertian Klasifikasi dan Regresi

Klasifikasi menghasilkan kelas diskrit, seperti malignant atau benign. Regresi menghasilkan angka kontinu, seperti harga. Perbedaan target menentukan metrik, bentuk prediksi, dan algoritma yang sesuai. Kode menggunakan pola antarmuka model yang sama, yaitu `fit` untuk belajar dari data dan `predict` atau `score` untuk menghasilkan keluaran.

3.2 Generalisasi, Underfitting, dan Overfitting

Tujuan model bukan menghafal data latih, melainkan bekerja pada data yang belum pernah dilihat. Model terlalu sederhana mengalami underfitting, sedangkan model terlalu rumit dapat mengikuti noise dan mengalami overfitting. Parameter `k` pada KNN, kedalaman pohon, nilai `C` pada SVM, `alpha` pada regularisasi, dan jumlah unit neural network mengatur keseimbangan fleksibilitas dan generalisasi.

3.3 Dataset Sintetis dan Dataset Contoh

Forge digunakan untuk menampilkan dua kelas dalam dua dimensi. Wave memperlihatkan hubungan nonlinear sederhana pada regresi. Breast cancer menjadi contoh data nyata dengan 30 fitur dan dua kelas. Boston digunakan untuk regresi, termasuk versi extended dengan fitur polinomial. Blobs, moons, dan circles digunakan karena bentuk geometri datanya dapat dikontrol.

3.4 K Nearest Neighbors untuk Klasifikasi

Kode KNN membagi data forge, membuat `KNeighborsClassifier`, menjalankan `fit`, lalu mencetak prediksi dan akurasi. Dengan tiga tetangga, akurasi data uji tercatat 0,86. Eksperimen `k` sama dengan 1, 3, dan 9 menunjukkan bahwa `k` kecil menghasilkan batas keputusan berliku dan sensitif terhadap noise, sedangkan `k` besar menghasilkan batas yang lebih halus.

3.5 K Nearest Neighbors untuk Regresi

`KNeighborsRegressor` digunakan pada dataset wave. Model memprediksi nilai berdasarkan rata rata tetangga terdekat. Skor R kuadrat data uji tercatat 0,83. Model mampu mengikuti pola lokal, tetapi prediksi dapat menjadi bertanggung ketika jumlah tetangga sedikit.

3.6 Kelebihan dan Kekurangan KNN


KNN mudah dipahami karena tidak membangun parameter model yang rumit. Kekurangannya adalah prediksi dapat lambat pada data besar dan sensitif terhadap skala fitur. Scaling dan pemilihan nilai k melalui validasi menjadi hal penting.

3.7 Regresi Linear Biasa

Pada wave, koefisien sekitar 0,394 dan intercept sekitar minus 0,032. Skor data latih 0,67 dan data uji 0,66 menunjukkan kapasitas model linear sederhana masih terbatas. Pada extended Boston, fitur polinomial menaikkan skor data latih menjadi 0,95 tetapi skor data uji turun menjadi 0,61 sehingga menunjukkan overfitting.

3.8 Ridge Regression

Ridge menambahkan penalti kuadrat terhadap koefisien. Alpha 1 menghasilkan skor data latih 0,89 dan data uji 0,75. Alpha 10 menurunkan skor menjadi 0,79 dan 0,64. Alpha 0,1 menghasilkan skor data latih 0,93 dan data uji 0,77. Alpha mengatur kuatnya penyusutan koefisien.



Gambar 1. Perbandingan skor regresi pada data latih dan data uji.

3.9 Lasso Regression

Lasso memakai penalti nilai mutlak dan dapat membuat sebagian koefisien menjadi nol. Pada alpha bawaan, empat fitur dipakai dengan skor data latih 0,29 dan data uji 0,21. Pada alpha 0,001, 33 fitur dipakai dengan skor 0,90 dan 0,77. Jika alpha terlalu kecil, 96 fitur digunakan dan skor data uji turun menjadi 0,64. Lasso berfungsi sebagai regularisasi sekaligus seleksi fitur.

3.10 Model Linear untuk Klasifikasi

Logistic Regression dan Linear SVC menggunakan batas keputusan linear. Logistic Regression dengan konfigurasi umum menghasilkan skor data latih sekitar 0,944 dan data uji 0,951. C sama dengan 100 menaikkan skor data uji menjadi 0,958, sedangkan C sama dengan 0,01 menurunkannya menjadi 0,930. Penalti L1 dan perubahan C juga mengubah bobot fitur.

3.11 Logistic Regression Multiclass

Dataset blobs dengan tiga pusat digunakan untuk memperlihatkan klasifikasi multiclass. Linear SVC menghasilkan matriks koefisien berbentuk 3 kali 2 dan tiga nilai intercept. Setiap kelas memiliki fungsi keputusan sendiri sehingga wilayah keputusan dapat divisualisasikan.

3.12 Naive Bayes

Naive Bayes menghitung jumlah kemunculan fitur pada setiap kelas dan membangun probabilitas berdasarkan asumsi independensi bersyarat. Pelatihannya cepat dan kebutuhan datanya ringan, tetapi asumsi antar fitur tidak selalu benar. Metode ini sesuai sebagai baseline terutama pada data hitungan dan teks.

3.13 Decision Tree: Pembangunan Model

Decision tree tanpa pembatasan kedalaman memperoleh skor data latih 1,000 dan data uji 0,937. Ketika max depth dibatasi menjadi 4, skor data latih turun menjadi 0,988 dan data uji naik menjadi 0,951. Pembatasan kedalaman mengurangi kompleksitas dan memperbaiki generalisasi.

3.14 Decision Tree: Interpretasi dan Feature Importance

Fitur worst radius memiliki kontribusi sekitar 0,727 dan worst concave points sekitar 0,122. Feature importance membantu melihat fitur yang sering digunakan dalam pembagian pohon, tetapi tidak sama dengan hubungan sebab akibat dan dapat bias ketika fitur saling berkorelasi.

3.15 Decision Tree untuk Regresi dan Ekstrapolasi


Pohon dapat mengikuti data latih dengan baik, tetapi kesulitan melakukan ekstrapolasi di luar rentang data yang pernah dilihat. Regresi linear dapat meneruskan tren lebih jauh. Pilihan algoritma harus disesuaikan dengan kebutuhan prediksi.

3.16 Random Forest

Random Forest membangun banyak decision tree menggunakan sampel dan subset fitur berbeda. Pada breast cancer, skor data uji mencapai 0,972 dan skor data latih 1,000. Ensemble membuat batas keputusan lebih stabil, tetapi tetap memerlukan validasi silang dan tuning.

3.17 Gradient Boosting

Gradient Boosting membangun model secara berurutan untuk memperbaiki kesalahan model sebelumnya. Konfigurasi dasar memperoleh skor data latih 1,000 dan data uji 0,965. Max depth sama dengan 1 menghasilkan skor data latih 0,991 dan data uji 0,972. Parameter depth, learning rate, dan jumlah estimator perlu dicari bersama.



Gambar 2. Perbandingan akurasi model klasifikasi yang ditampilkan oleh kode.

3.18 Support Vector Machine dengan Fitur Nonlinear


Linear SVC menunjukkan keterbatasan batas lurus pada data blobs. Penambahan fitur kuadrat memproyeksikan data ke ruang lebih tinggi sehingga pemisahan linear dapat menghasilkan batas melengkung ketika dilihat pada ruang asli.

3.19 Kernel Trick

SVC dengan kernel radial basis function menghitung kemiripan pada ruang fitur lebih tinggi tanpa membangun seluruh fitur baru secara eksplisit. C mengatur toleransi kesalahan, sedangkan gamma mengatur jangkauan pengaruh sebuah titik.

3.20 Tuning SVM dan Scaling

SVC tanpa scaling menghasilkan akurasi data uji 0,94. MinMax scaling meningkatkan akurasi menjadi 0,97 dan Standard scaling menghasilkan 0,96. Ketika C menjadi 1000, skor data latih mencapai 1,000 tetapi skor data uji turun menjadi 0,958. Hal ini menjadi indikasi overfitting.



Gambar 3. Pengaruh scaling terhadap akurasi SVM.

3.21 Neural Network dan MLP

MLPClassifier digunakan untuk memvisualisasikan batas keputusan nonlinear. Pada breast cancer tanpa scaling, skor data uji 0,92. Setelah scaling, skor data latih menjadi 0,991 dan data uji 0,965. Dengan max iter 1000, skor data uji menjadi 0,972. Penambahan alpha sama dengan 1 menurunkan skor latih menjadi 0,988 dengan skor uji tetap 0,972.

3.22 Estimasi Ketidakpastian

Decision function menunjukkan jarak bertanda dari batas keputusan. Nilai positif dan negatif menentukan kelas, sedangkan besarnya nilai menunjukkan keyakinan relatif. predict_proba menghasilkan probabilitas kelas. Pada Iris, decision function berbentuk 3 kali 3 dan argmax memilih kelas dengan nilai terbesar. Probabilitas bukan jaminan kebenaran dan sebaiknya dikalibrasi untuk keputusan penting.

3.23 Ringkasan Analisis

Bagian	Hasil utama	Interpretasi
--------	-------------	--------------

KNN klasifikasi	Akurasi uji 0,86	Baik untuk pola lokal; sensitif terhadap k dan skala
KNN regresi	R kuadrat uji 0,83	Mampu mengikuti wave; prediksi berbasis tetangga
Regresi linear	Skor uji 0,66	Model sederhana; kapasitas terbatas
Ridge dan Lasso	Skor uji sampai 0,77	Regularisasi membantu generalisasi
Logistic regression	Akurasi uji sampai 0,958	Parameter C mengatur regularisasi
Random Forest	Akurasi uji 0,972	Ensemble stabil tetapi dapat overfit pada data latih
Gradient Boosting	Akurasi uji sampai 0,972	Kedalaman dan learning rate perlu dituning
SVM scaled	Akurasi uji 0,972	Scaling penting ketika skala fitur berbeda
MLP scaled	Akurasi uji 0,972	Scaling, iterasi, dan alpha sangat berpengaruh

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Analisis ini menunjukkan bahwa supervised learning adalah rangkaian keputusan yang saling terkait. Pemilihan algoritma, pembagian data, pembentukan fitur, regularisasi, parameter, dan metrik evaluasi perlu dibaca sebagai satu proses. Model dengan kompleksitas tinggi tidak otomatis menghasilkan generalisasi terbaik.

Hasil paling kuat muncul pada model yang dipadukan dengan pengaturan yang sesuai. Ridge dan Lasso memperlihatkan manfaat regularisasi, decision tree memperlihatkan risiko overfitting, ensemble menghasilkan performa kuat, dan SVM serta MLP memperoleh peningkatan setelah scaling. Semua hasil tetap perlu diuji dengan validasi yang lebih luas.

4.2 Saran

Untuk pengembangan lanjutan, gunakan pipeline dan validasi silang sebelum memilih model. Evaluasi juga perlu dilengkapi dengan confusion matrix, precision, recall, F1 score, dan ROC AUC agar penilaian tidak hanya bergantung pada akurasi. Versi Python dan pustaka perlu dicatat karena beberapa API lama dapat berubah, sedangkan beberapa random state dan pembagian data perlu diuji untuk melihat kestabilan skor.

Skor dari satu notebook sebaiknya tidak dijadikan jaminan performa pada data produksi. Model perlu diuji kembali pada data yang lebih beragam, dipantau setelah digunakan, dan dibandingkan dengan kebutuhan nyata dari sistem yang akan dibangun.

PETUNJUK MENJALANKAN NOTEBOOK

Notebook dapat dijalankan menggunakan Jupyter Notebook atau JupyterLab. Pasang numpy, scipy, scikit learn, matplotlib, pandas, pillow, joblib, mglearn, dan jupyter. Jalankan sel dari atas ke bawah. Pisahkan data latih dan data uji sebelum preprocessing. Jika muncul peringatan konvergensi, tingkatkan jumlah iterasi, lakukan scaling, atau tinjau parameter regularisasi. Jika fungsi Boston tidak tersedia, gunakan data regresi pengganti atau data lokal yang sudah disimpan.

DAFTAR PUSTAKA

Müller, A. C., & Guido, S. (2017). *Introduction to machine learning with Python: A guide for data scientists*. O'Reilly Media.

Müller, A. C. (n.d.). *Introduction to machine learning with Python: supervised learning notebook* [Jupyter Notebook]. GitHub.

https://github.com/amueller/introduction_to_ml_with_python