

**LAPORAN ANALISIS KODE
MACHINE LEARNING
PREPROCESSING DAN UNSUPERVISED LEARNING**



Disusun Oleh

Nama	: Muhammad Yusuf Arrayyan
NPM	: G1A024009
Kelas	: A

Dosen Pengampu

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU**

2026

PENDAHULUAN

1.1 Latar Belakang

Buku Introduction to Machine Learning with Python membahas preprocessing dan unsupervised learning melalui scaling, transformasi fitur, reduksi dimensi, pembelajaran manifold, faktorisasi matriks, serta clustering. Materi ini menunjukkan bahwa kualitas representasi data sangat menentukan hasil analisis karena perubahan skala, bentuk fitur, dan dimensi dapat memengaruhi cara model membaca struktur data.

Laporan ini menganalisis seluruh kelompok kode pada tema tersebut secara berurutan. Setiap bagian dibahas berdasarkan tujuan kode, bentuk data, proses komputasi, hasil visual atau numerik, interpretasi, dan keterbatasan ketika metode digunakan pada data nyata.

1.2 Tujuan Analisis

Analisis ini bertujuan untuk membahas dan mendokumentasikan seluruh kode serta materi preprocessing dan unsupervised learning secara lengkap. Pembahasan mencakup preprocessing, scaling, transformasi fitur, pencegahan data leakage, PCA, NMF, t SNE, K Means, vector quantization, agglomerative clustering, dendrogram, DBSCAN, evaluasi clustering dengan ground truth, dan evaluasi tanpa ground truth. Setiap bagian kode dijelaskan berdasarkan fungsi, bentuk data, parameter, proses komputasi, keluaran visual atau numerik, interpretasi, dan keterbatasannya. Dengan demikian, laporan ini mencakup seluruh alur kode dan seluruh pokok bahasan tema tersebut, kemudian merumuskan perbandingan metode, kesimpulan, dan saran berdasarkan hasil analisis.

1.3 Sumber dan Metode Analisis

Sumber utama analisis adalah notebook kode G1A024009_Laporan_Kode_Preprocessing_dan_Unsupervised_Learning.ipynb yang membahas preprocessing dan unsupervised learning. Laporan mengikuti urutan blok kode, dataset, parameter, proses komputasi, keluaran, interpretasi, dan keterbatasan. Hasil dapat berubah karena versi pustaka dan random state yang digunakan.

Keluaran yang dicatat meliputi bentuk matriks, jumlah komponen, akurasi, jumlah cluster, titik noise, ukuran kelompok, silhouette score, dan Adjusted Rand Index. Label hanya digunakan untuk evaluasi setelah clustering, bukan untuk membentuk cluster.

RANGKUMAN DATA DAN ALUR KODE

2.1 Dataset Utama

Data	Ukuran atau karakteristik	Bagian kode
Breast cancer Wisconsin	569 observasi dan 30 fitur	Scaling, PCA, dan evaluasi preprocessing
Citra wajah	Data citra banyak kelas	PCA, NMF, K Means, agglomerative, DBSCAN
Digits	Citra digit berdimensi tinggi	PCA awal dan t SNE
Blobs	Data buatan dengan pusat kelompok terkontrol	K Means dan agglomerative
Moons dan circles	Data dengan bentuk melengkung	K Means dan DBSCAN
Sinyal sintetis	2000 observasi dan 100 pengukuran	NMF untuk pemulihan komponen

2.2 Alur Umum Kode

Analisis dimulai dengan pembagian data dan penerapan transformasi. Scaler dipelajari menggunakan data latih, kemudian data latih dan data uji ditransformasi menggunakan objek yang sama. Setelah itu data dapat direduksi, divisualisasikan, atau dikelompokkan. Pada clustering, target tidak digunakan untuk membentuk kelompok. Jika label tersedia, label hanya dipakai setelah proses selesai untuk mengevaluasi hasil.

2.3 Konsep Evaluasi yang Muncul Berulang

Preprocessing harus dipelajari dari data latih agar tidak terjadi data leakage. PCA memilih arah dengan variasi terbesar, bukan arah yang pasti paling baik untuk klasifikasi. Oleh sebab itu, hasil reduksi dimensi perlu dievaluasi sesuai tujuan analisis dan tidak cukup dinilai hanya dari visualisasi.

t SNE bersifat eksploratif sehingga bentuk dan jarak global tidak boleh dibaca secara berlebihan. K Means membutuhkan jumlah cluster sejak awal dan cenderung sesuai untuk kelompok bulat dengan ukuran sebanding, sedangkan DBSCAN dapat menemukan noise dan bentuk yang tidak cembung tetapi sensitif terhadap eps dan min samples. Nomor label cluster dapat tertukar, sehingga ARI lebih tepat daripada akurasi label mentah ketika ground truth tersedia.

2.4 Hubungan Dataset dan Teknik Analisis

Pemilihan metode mengikuti bentuk data: scaling dan PCA untuk breast cancer, t SNE untuk digits, K Means dan agglomerative untuk blobs, serta DBSCAN untuk moons dan circles. NMF digunakan pada sinyal non-negatif karena komponen laten dapat dipulihkan dari matriks campuran.

ANALISIS LENGKAP: PREPROCESSING DAN UNSUPERVISED LEARNING

3.1 Pengertian Unsupervised Learning

Pada pembelajaran tanpa pengawasan, target kelas tidak menjadi masukan utama. Model mencari pola berdasarkan geometri, kepadatan, atau hubungan antar fitur. Tidak ada jawaban tunggal yang selalu benar karena algoritma berbeda dapat menemukan struktur yang berbeda.

3.2 Tantangan Analisis Tanpa Label

Tanpa label, kualitas hasil tidak dapat dinilai hanya dengan akurasi. Jumlah cluster perlu dipilih, skala fitur perlu dikendalikan, dan noise perlu dibedakan dari kelompok kecil. Jika label tersedia, ARI dapat digunakan setelah clustering. Jika label tidak tersedia, silhouette score dan pemeriksaan visual dapat membantu, tetapi tetap memerlukan pengetahuan domain.

3.3 Jenis Preprocessing

MinMaxScaler memetakan fitur ke rentang nol sampai satu. StandardScaler memusatkan fitur pada rata-rata nol dan simpangan baku satu. Normalizer menormalkan panjang vektor. Quantile transformation mengubah distribusi fitur agar lebih seragam. Pemilihan transformasi bergantung pada algoritma dan distribusi data.

```
minmax = MinMaxScaler().fit(X_train)
X_train_mm = minmax.transform(X_train)
X_test_mm = minmax.transform(X_test)
```

3.4 Menerapkan Transformasi pada Data Latih dan Data Uji

Pada breast cancer, data dibagi menjadi 426 data latih dan 143 data uji. Scaler dipelajari menggunakan data latih. Data uji hanya ditransformasi menggunakan scaler yang sama. Jika scaler dipelajari dari seluruh data sebelum pembagian, informasi distribusi data uji masuk ke proses belajar dan evaluasi menjadi terlalu optimistis. Karena itu preprocessing harus berada di dalam pipeline dan proses validasi.


```
scaler = StandardScaler().fit(X_train)
X_train_std = scaler.transform(X_train)
X_test_std = scaler.transform(X_test)
```

3.5 Pengaruh Preprocessing pada Supervised Learning

SVC tanpa scaling menghasilkan akurasi data uji 0,94. MinMax scaling meningkatkan skor menjadi 0,97 dan Standard scaling menghasilkan 0,96. Perubahan ini

menunjukkan bahwa bentuk data sebelum model sama pentingnya dengan pilihan model, terutama pada metode berbasis jarak dan margin seperti KNN serta SVM.

```
models = {  
    "MinMax": make_pipeline(  
        MinMaxScaler(), SVC(C=10)),  
    "Standard": make_pipeline(  
        StandardScaler(), SVC(C=10)),  
}
```



Gambar 1. Pengaruh scaling terhadap akurasi SVM.


3.6 PCA sebagai Reduksi Dimensi

Principal Component Analysis mencari arah variasi terbesar dan menyusun komponen yang saling ortogonal. Data breast cancer berukuran 569 kali 30 direduksi menjadi 569 kali 2. PCA membantu visualisasi, tetapi arah variasi terbesar tidak selalu menjadi arah terbaik untuk klasifikasi. Jumlah komponen perlu dipilih berdasarkan kebutuhan kompresi dan hasil validasi.

```
pca = make_pipeline(  
    StandardScaler(), PCA(n_components=2))  
X_pca = pca.fit_transform(cancer.data)
```

3.7 PCA pada Citra Wajah

KNN langsung pada citra wajah menghasilkan akurasi data uji sekitar 0,23. Setelah PCA dengan 100 komponen dan whitening, akurasi meningkat menjadi 0,31. Kenaikan ini menunjukkan bahwa proyeksi dapat mengurangi noise dan membuat jarak antar wajah lebih informatif, walaupun hasilnya masih belum tinggi.



Gambar 2. Perubahan akurasi KNN setelah ekstraksi fitur PCA pada citra wajah.

3.8 Non Negative Matrix Factorization pada Data Sintetis

NMF memfaktorkan matriks non negatif menjadi dua matriks yang juga non negatif. Kode membuat tiga sinyal dasar, mencampurnya menjadi data berukuran 2000 kali 100, lalu meminta NMF memulihkan tiga komponen. NMF sesuai untuk intensitas piksel, jumlah kata, atau sinyal sensor karena komponennya dapat dibaca sebagai bagian penyusun.

```
nmf = NMF(n_components=3, init="nndsvda",
          random_state=RANDOM_STATE,
          max_iter=1000)
S_recovered = nmf.fit_transform(X_signal)
```

3.9 NMF pada Citra Wajah

NMF menghasilkan basis wajah dan koefisien untuk setiap gambar. Basis dapat dipandang sebagai pola bagian wajah. Berbeda dari PCA yang mencari arah variasi ortogonal, NMF mencari kombinasi komponen yang seluruhnya tidak negatif. Hasilnya dapat lebih lokal, tetapi rekonstruksi dan jumlah komponen tetap perlu dievaluasi.

3.10 t SNE

t SNE memetakan data berdimensi tinggi ke dua dimensi dengan mempertahankan hubungan ketetanggaan lokal. Kode menerapkannya pada digits setelah PCA awal. Hasil t SNE bersifat eksploratif karena dapat berubah ketika perplexity atau random state berubah. Jarak global dan pemisahan visual tidak otomatis bermakna bagi klasifikasi.

```
digits_pca = PCA(n_components=30).fit_transform(
    StandardScaler().fit_transform(digits.data))
```

```
digits_tsne = TSNE(
    n_components=2, perplexity=30,
    random_state=RANDOM_STATE).fit_transform(digits_pca)
```

3.11 K Means

K Means memilih centroid, menetapkan titik ke centroid terdekat, menghitung centroid baru, lalu mengulang. Metode ini membutuhkan jumlah cluster sejak awal dan paling sesuai untuk kelompok relatif bulat dengan ukuran sebanding. Pada moons, satu lengkungan dapat terpecah menjadi banyak cluster kecil saat k terlalu besar.

```
kmeans = KMeans(
    n_clusters=3, n_init=20,
    random_state=RANDOM_STATE).fit(X_blob)
labels = kmeans.labels_
```

3.12 K Means pada Data dengan Variasi dan Outlier

K Means tetap memaksa semua titik masuk ke salah satu cluster dan centroid dapat tertarik oleh outlier. Contoh dengan simpangan baku berbeda menunjukkan bahwa asumsi bentuk dan ukuran cluster sangat memengaruhi hasil.

3.13 Vector Quantization

K Means dapat dipandang sebagai vector quantization. Setiap centroid menjadi representasi ringkas dan setiap titik diganti dengan centroid terdekat. Cara pandang ini berguna untuk kompresi, clustering, dan pembentukan fitur jarak.

3.14 Agglomerative Clustering

Agglomerative clustering dimulai dari banyak kelompok kecil. Dua kelompok terdekat digabung secara bertahap. Parameter linkage menentukan cara jarak antar kelompok dihitung. Berbeda dari K Means, proses penggabungan dapat dipahami melalui struktur hierarkis.

```
agg = AgglomerativeClustering(
    n_clusters=3, linkage="ward").fit(X_blob)
labels = agg.labels_
```

3.15 Dendrogram

Dendrogram menampilkan jarak ketika dua kelompok digabung. Penggabungan pada ketinggian rendah berarti kelompok dekat, sedangkan ketinggian tinggi menunjukkan perubahan struktur yang besar. Dendrogram membantu memilih jumlah cluster dengan memotong pohon pada ketinggian tertentu.

3.16 DBSCAN

DBSCAN membentuk kelompok berdasarkan kepadatan. Titik dengan tetangga yang cukup dekat menjadi inti cluster, sedangkan titik yang tidak memenuhi kepadatan

dapat diberi label minus satu sebagai noise. Parameter default dapat membuat semua titik dianggap noise.

```
dbscan = DBSCAN(  
    eps=.3, min_samples=5).fit(X_moon)  
labels_db = dbscan.labels_
```

3.17 DBSCAN pada Moons

Pada data moons, DBSCAN dapat mengikuti bentuk lengkung lebih baik daripada K Means. Hasil sangat dipengaruhi eps dan min samples. Scaling perlu dilakukan terlebih dahulu agar jarak tidak dipengaruhi satuan fitur.

3.18 Evaluasi Clustering dengan Ground Truth

Kode membandingkan label hasil clustering dengan ground truth menggunakan accuracy score dan ARI. Pada satu contoh, accuracy score adalah 0,00 sedangkan ARI adalah 1,00. Hal ini terjadi karena nomor label dapat tertukar. ARI mengatasi pertukaran label tersebut.


```
ari = adjusted_rand_score(  
    y_moon, labels_db)  
print("ARI:", round(ari, 3))
```

3.19 Evaluasi Clustering Tanpa Ground Truth

Ketika ground truth tidak tersedia, silhouette score atau pemeriksaan visual dapat digunakan. Silhouette menilai apakah titik lebih dekat dengan cluster sendiri daripada cluster lain. Nilai tinggi tidak menjamin kelompok tersebut bermakna bagi masalah sehingga pengetahuan domain tetap diperlukan.

3.20 DBSCAN pada Citra Wajah

Citra wajah direduksi menggunakan PCA sebelum DBSCAN diterapkan. Dengan min samples 3 dan eps 15, diperoleh satu cluster dan 32 titik noise. Pengujian eps pada nilai 1, 3, 5, 7, 9, 11, dan 13 menghasilkan jumlah cluster 1, 1, 1, 14, 4, 2, dan 2. Perubahan ini menunjukkan sensitivitas ruang fitur terhadap eps.




Gambar 3. Jumlah cluster DBSCAN pada beberapa nilai eps.

3.21 K Means pada Citra Wajah

K Means dengan 10 cluster menghasilkan ukuran kelompok 282, 226, 105, 268, 151, 324, 202, 208, 208, dan 89. Ukuran yang tidak sama menunjukkan bahwa centroid membagi ruang berdasarkan jarak, bukan jumlah anggota yang sama.

3.22 Agglomerative pada Citra Wajah

Agglomerative dengan jumlah cluster yang sama menghasilkan ukuran kelompok 169, 660, 144, 329, 217, 85, 18, 261, 31, dan 149. ARI antara K Means dan agglomerative adalah 0,10. Nilai ini menunjukkan pembagian anggota yang berbeda karena kedua algoritma memakai asumsi dan fungsi objektif berbeda.



Gambar 4. Perbandingan ARI hasil clustering citra wajah terhadap hasil pembandingan.

3.23 Ringkasan Analisis

Bagian	Keluaran utama	Makna analitis
MinMax scaling	Fitur data latih berada pada rentang nol sampai satu	Jarak dan skala menjadi lebih seimbang
SVM setelah scaling	Akurasi naik dari 0,94 menjadi 0,97	Preprocessing dapat mengubah performa
PCA breast cancer	569 kali 30 menjadi 569 kali 2	Visualisasi lebih ringkas
PCA wajah	Akurasi naik dari 0,23 menjadi 0,31	Ekstraksi fitur membantu KNN
NMF sinyal	2000 kali 100 menjadi tiga sinyal laten	Komponen tersembunyi dapat dipulihkan
K Means moons	Banyak cluster kecil saat k sama dengan 10	Asumsi cluster bulat tidak sesuai
DBSCAN wajah	Jumlah cluster berubah dari 1 sampai 14	Sangat sensitif terhadap eps
ARI moons	Accuracy 0,00 dan ARI 1,00	Label dapat tertukar
Wajah K Means dan agglomerative	ARI 0,10	Algoritma menemukan pembagian berbeda

PEMBAHASAN TERPADU

4.1 Hubungan Preprocessing dan Model

Pembahasan menunjukkan bahwa algoritma tidak dapat dipisahkan dari representasi data. Scaling mengubah jarak dan margin sehingga SVM memperoleh peningkatan akurasi. PCA mengurangi dimensi dan membuat KNN pada citra wajah lebih informatif. Namun, reduksi dimensi tetap perlu disesuaikan dengan tujuan, karena representasi yang baik untuk visualisasi belum tentu paling baik untuk prediksi.

4.2 Perbandingan Metode Clustering

K Means sesuai untuk kelompok relatif bulat dan membutuhkan jumlah cluster. Agglomerative menghasilkan struktur hierarkis yang dapat dibaca melalui dendrogram. DBSCAN menemukan kelompok berdasarkan kepadatan dan dapat menandai noise. Pada moons, DBSCAN lebih sesuai dengan bentuk lengkung, sedangkan pada citra wajah hasil K Means dan agglomerative berbeda cukup jauh.

4.3 Risiko Kesalahan dan Reprodusibilitas

Hasil clustering dapat berubah karena skala fitur, random state, jumlah cluster, linkage, eps, dan min samples. Visual t SNE juga dapat berubah karena perplexity dan inisialisasi. Oleh karena itu, evaluasi perlu dilakukan dengan beberapa nilai parameter, beberapa random state, metrik internal, dan pemahaman domain. Preprocessing harus berada di dalam pipeline agar tidak terjadi kebocoran informasi.

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Analisis ini menunjukkan bahwa preprocessing dan unsupervised learning merupakan proses pengambilan keputusan, bukan sekadar menjalankan algoritma. Scaling dapat mengubah performa model. PCA dan NMF memberi representasi yang berbeda. t SNE berguna untuk eksplorasi lokal. K Means, agglomerative, dan DBSCAN membuat asumsi berbeda mengenai bentuk, jarak, dan kepadatan kelompok.

Hasil clustering tidak boleh dibaca otomatis. ARI menunjukkan pentingnya metrik yang tidak terpengaruh pertukaran nomor label, sedangkan DBSCAN memperlihatkan perlunya analisis sensitivitas. Pemilihan metode harus mempertimbangkan struktur data, tujuan analisis, interpretasi hasil, dan pengetahuan domain.

5.2 Saran

Gunakan pipeline agar preprocessing dipelajari hanya dari data latih, lalu uji beberapa jumlah komponen PCA dan beberapa random state. Jika label pembandingan tersedia, gunakan silhouette, ARI, dan NMI secara bersama sama. Kestabilan K Means, agglomerative, DBSCAN, NMF, dan t SNE juga perlu diuji pada beberapa parameter agar kesimpulan tidak bergantung pada satu konfigurasi.

Visualisasi sebaiknya digunakan sebagai alat eksplorasi, bukan satu satunya bukti keputusan. Pengetahuan domain tetap diperlukan untuk menentukan apakah cluster yang ditemukan benar benar bermakna dan dapat digunakan untuk menjawab masalah yang dianalisis.

DAFTAR PUSTAKA

Müller, A. C., & Guido, S. (2017). *Introduction to machine learning with Python: A guide for data scientists*. O'Reilly Media.

Müller, A. C. (n.d.). *Introduction to machine learning with Python: preprocessing and unsupervised learning notebook* [Jupyter Notebook]. GitHub.

https://github.com/amueller/introduction_to_ml_with_python